概述和要求

BeeGFS on NetApp with E-Series Storage

NetApp
March 21, 2024

This PDF was generated from https://docs.netapp.com/zh-cn/beegfs/beegfs-solution-overview.html on March 21, 2024. Always check docs.netapp.com for the latest.

目录

概述和要求 1
解决方案概述 1
设计代数 2
架构概述 3
技术要求 5

概述和要求

解决方案概述

NetApp解决方案 上的BeeGFS将BeeGFS并行文件系统与NetApp EF600存储系统相结合、打造了一个可靠、可扩展且经济高效的基础架构、可满足苛刻的工作负载要求。

这种设计利用了最新企业级服务器和存储硬件以及网络速度所提供的性能密度、 要求文件节点采用双AMD EPYC 7003 "米兰"处理器并支持使用200 GB (HDR) InfiniBand直接连接的PCIe 4.0、以块节点使用NVMe/IB协议提供端到端NVMe和NVMeOF。

NVA计划

NetApp解决方案 上的BeeGFS是NetApp验证架构(NVA)计划的一部分、该计划为客户提供针对特定工作负载和使用情形的参考配置和规模估算指导。NVA解决方案经过全面测试和设计、可最大限度地降低部署风险并加快上市速度。

用例

以下使用情形适用于NetApp解决方案 上的BeeGFS：

- 人工智能(AI)、包括机器学习(ML)、深度学习(DL)、大规模自然语言处理(NLP)和自然语言理解(NLF)。有关详细信息，请参见 "BeeGFS for AI：事实与虚构"。
- 高性能计算(HPC)、包括通过MPI (消息传递接口)和其他分布式计算技术加速的应用程序。有关详细信息，请参见 "BeeGFS为何超越HPC"。
- 应用程序工作负载的特征为：
  - 读取或写入大于1 GB的文件
  - 多个客户端(10、100和1000)读取或写入同一文件
- 多TB或多PB数据集。
- 需要一个存储命名空间的环境、可以优化大小文件的组合。

优势

在NetApp上使用BeeGFS的主要优势包括：

- 提供经验证的硬件设计、可实现硬件和软件组件的全面集成、以确保可预测的性能和可靠性。
- 使用Ansible进行部署和管理、以实现规模化的精简性和一致性。
- 使用E系列性能分析器和BeeGFS插件提供监控和可观察性。有关详细信息，请参见 "介绍用于监控NetApp E系列解决方案的框架"。
- 高可用性采用共享磁盘架构、可提供数据持久性和可用性。
- 支持使用容器和Kubernetes进行现代工作负载管理和流程编排。有关详细信息，请参见 "Kubernetes认识BeeGFS：一个适应未来需求的投资故事"。

HA架构

NetApp上的BeeGFS通过创建与NetApp硬件完全集成的解决方案 来扩展BeeGFS企业版的功能、从而实现共享磁盘高可用性(HA)架构。

> 虽然BeeGFS社区版可以免费使用、但企业版要求从NetApp等合作伙伴购买专业支持订阅合同。企业版支持使用多项附加功能、包括故障恢复能力、配额强制实施和存储池。

下图对无共享和共享磁盘HA架构进行了比较。

[]

有关详细信息，请参见 "宣布NetApp支持的BeeGFS高可用性"。

Ansible

NetApp上的BeeGFS是使用Ansible自动化交付和部署的、Ansible自动化托管在GitHub和Ansible GALAXY上(BeeGFS集合可从获取 "Ansible Galax河" 和 "NetApp的E系列GitHub"）。虽然Ansible主要是使用用于组装BeeGFS组件的硬件进行测试的、但您可以将其配置为使用受支持的Linux版本在几乎任何基于x86的服务器上运行。

有关详细信息，请参见 "使用E系列存储部署BeeGFS"。

设计代数

NetApp解决方案 上的BeeGFS目前正处于第二代设计阶段。

第一代和第二代均采用一种基础架构、其中整合了BeeGFS文件系统和NVMe EF600存储系统。但是、第二代基于第一代产品构建、其中包括以下附加优势：

- 将性能和容量提高一倍、同时仅添加2U机架空间
- 高可用性(High Availability、HA)基于共享磁盘的两层硬件设计
- NVIDIA DGX A100 SuperPOD和NVIDIA BasePOD架构的外部认证

第二代设计

基于NetApp的第二代BeeGFS经过优化、可满足高性能计算(HPC)和HPC模式机器学习(ML)、深度学习(DL)以及类似人工智能(AI)技术等苛刻工作负载的性能要求。通过整合共享磁盘高可用性(HA)架构、NetApp解决方案 上的BeeGFS还可以满足企业和其他组织在寻找可扩展的存储以适应其工作负载和使用情形时无法承受停机或数据丢失的需求。此解决方案 不仅已通过NetApp的验证、还通过了外部认证、作为NVIDIA DGX SuperPOD和DGX BasePOD的存储选项。

第一代设计

第一代基于NetApp的BeeGFS专为使用NetApp EF600 NVMe存储系统、BeeGFS并行文件系统、NVIDIA DGX®A100系统和NVIDIA®Mellanox®Quantum®QM8700 200 Gbps IB交换机的机器学习(ML)和人工智能(AI)工作负载而设计。此设计还为存储和计算集群互连网络结构提供了200 Gbps InfiniBand (IB)、可为高性能工作负载提供完全基于IB的架构。

有关第一代产品的详细信息、请参见 "采用NVIDIA DGX A100系统和BeeGFS的NetApp EF系列AI"。

架构概述

NetApp解决方案 上的BeeGFS包括用于确定支持经验证的工作负载所需的特定设备、布线和配置的架构设计注意事项。

构建块架构

根据存储要求、可以使用不同的方式部署和扩展BeeGFS文件系统。例如、以大量小文件为主要特征的使用情形将受益于额外的元数据性能和容量、而大文件较少的使用情形则可能有利于提高实际文件内容的存储容量和性能。这些多种注意事项会影响并行文件系统部署的不同维度、从而增加了文件系统设计和部署的复杂性。

为了应对这些挑战、NetApp设计了一个标准的构建块架构、用于横向扩展其中的每个方面。通常、BeeGFS组件部署在以下三种配置文件之一中：

- 一个基础组件、包括BeeGFS管理、元数据和存储服务
- BeeGFS元数据加上存储组件
- 仅供BeeGFS存储使用的组件

这三个选项之间的唯一硬件更改是使用较小的驱动器来获取BeeGFS元数据。否则、所有配置更改将通过软件应用。借助Ansible作为部署引擎、为特定组件设置所需的配置文件可以使配置任务变得简单明了。

有关更多详细信息、请参见 [经验证的硬件设计]。

文件系统服务

BeeGFS文件系统包括以下主要服务：

- *管理服务。*注册并监控所有其他服务。
- *存储服务。*存储称为数据区块文件的分布式用户文件内容。
- *元数据服务。*跟踪文件系统布局、目录、文件属性等。
- *客户端服务。*挂载文件系统以访问存储的数据。

下图显示了NetApp E系列系统中使用的BeeGFS解决方案 组件和关系。

[]

作为一个并行文件系统、BeeGFS会将其文件条带化到多个服务器节点上、以最大限度地提高读/写性能和可扩展性。服务器节点协同工作、可提供一个文件系统、其他服务器节点(通常称为_clients_）可以同时挂载和访问该文件系统。这些客户端可以查看和使用分布式文件系统、类似于NTFS、XFS或ext4等本地文件系统。

这四项主要服务在广泛支持的Linux分发版上运行、并通过任何支持TCP/IP或RDMA的网络进行通信、包括InfiniBand (IB)、OMNI-Path (OPA)和基于融合以太网的RDMA (RoCE)。BeeGFS服务器服务(管理、存储和元数据)是用户空间守护进程、而客户端是原生 内核模块(无修补)。所有组件均可在不重新启动的情况下安装或更新、您可以在同一节点上运行任何服务组合。

已验证节点

NetApp解决方案 上的BeeGFS包括以下经验证的节点：NetApp EF600存储系统(块节点)和联想ThinkSystem SR665服务器(文件节点)。

块节点：**EF600**存储系统

NetApp EF600全闪存阵列可提供一致、近乎实时的数据访问、同时支持任意数量的工作负载。为了快速、持续地向AI和HPC应用程序馈送数据、EF600存储系统在一个机箱中提供高达200万个缓存读取IOPS、低于100微秒的响应时间以及42 GBps顺序读取带宽。

文件节点：**Lenovo ThinkSystem SR665**服务器

SR665是一款采用PCIe 4.0的双插槽2U服务器。如果配置为满足此解决方案 的要求、则它可以提供充足的性能、以便在与直连E系列节点提供的吞吐量和IOPS相当的配置中运行BeeGFS文件服务。

有关联想SR665的详细信息、请参见 "联想的网站"。

经验证的硬件设计

该解决方案的组件(如下图所示)使用两个双插槽PCIe 4.0服务器作为BeeGFS文件层、并使用两个EF600存储系统作为块层。

[]

> 由于每个组件都包含两个BeeGFS文件节点、因此要在故障转移集群中建立仲裁、至少需要两个组件。虽然您可以配置双节点集群、但此配置具有一些限制、可能会阻止成功进行故障转移。如果您需要双节点集群、则可以将第三个设备作为Tiebreaker (但是、此站点不会介绍此设计)。

每个组件都通过两层硬件设计提供高可用性、这种设计可分隔文件层和块层的故障域。每个层都可以独立进行故障转移、从而提高故障恢复能力并降低级联故障的风险。将HDR InfiniBand与NVMeOF结合使用可在文件和块节点之间提供高吞吐量和最低延迟、并提供完全冗余和足够的链路超额预订、以避免分散设计成为瓶颈、即使系统部分降级也是如此。

NetApp解决方案 上的BeeGFS可跨部署中的所有组件运行。部署的第一个组件必须运行BeeGFS管理、元数据和存储服务(称为基础组件)。所有后续组件均通过软件配置为运行BeeGFS元数据和存储服务、或者仅运行存储服务。由于每个组件都具有不同的配置配置文件、因此可以使用相同的底层硬件平台和组件设计扩展文件系统元数据或存储容量和性能。

一个独立的Linux HA集群最多可组合五个组件、从而确保每个集群资源管理器(Pacemaker)有合理数量的资源、并降低保持集群成员同步所需的消息传送开销(Corosync)。建议每个集群至少有两个组件、以便有足够的成员建立仲裁。将这些独立BeeGFS HA集群中的一个或多个组合在一起、以创建一个BeeGFS文件系统(如下图所示)、此文件系统可作为一个存储命名空间供客户端访问。

[]

尽管每个机架的组件数量最终取决于给定站点的电源和散热要求、 解决方案 经过专门设计、可在一个42U机架中部署多达五个组件、同时仍可为用于存储/数据网络的两个1U InfiniBand交换机提供空间。每个构建块需要八个IB端口(每个交换机四个用于实现冗余)、因此五个构建块会在一个40端口HDR InfiniBand交换机(如NVIDIA QM8700)上保留一半的端口、以便实施ft-tree或类似的非阻塞拓扑。此配置可确保存储或计算/GPU机架的数量可以纵向扩展、而不会出现网络瓶颈。或者、可以根据存储网络结构供应商的建议使用超额预订的存储网络结构。

下图显示了一个80节点的ft-tree拓扑。

[]

通过使用Ansible作为部署引擎在NetApp上部署BeeGFS、管理员可以使用现代基础架构作为代码实践来维护整个环境。这样可以极大地简化原本复杂的系统、使管理员可以在一个位置定义和调整所有配置、然后确保无论环境扩展多大、都能始终如一地应用。可从获取BeeGFS集合 "Ansible Galax河" 和 "NetApp的E系列GitHub"。

技术要求

要在NetApp解决方案 上实施BeeGFS、请确保您的环境满足技术要求。

硬件要求

下表列出了在NetApp解决方案 上实施BeeGFS的单个第二代组件设计所需的硬件组件。

> 在任何特定解决方案 实施中使用的硬件组件可能会因客户要求而异。

计数	硬件组件	要求
2.	BeeGFS文件节点。	每个文件节点都应满足或超出以下配置、以实现预期性能。 处理器： • 2个AMD EPYC 7343 16C 3.2 GHz。 • 配置为两个NUMA分区。 内存： • 256 GB。 • 16个16 GB TruDDR4 3200MHz (2Rx8 1.2V) RDIMM-A (首选较小的DIMM、而不是较大的DIMM)。 • 填充以最大程度地提高内存带宽。 • PCIe扩展：四个PCE第4代x16插槽：* • 每个NUMA分区有两个插槽。 • 每个插槽都应为Mellanox MCX653106A-HDAT适配器提供足够的电源/散热。 其他： • 在RAID 1中为操作系统配置两个1 TB 7.2K SATA驱动器(或类似驱动器)。 • 10GbE OCP 3.0适配器(或类似适配器)、用于带内操作系统管理。 • 采用Redfish API的1GbE BMC、用于带外服务器管理。 • 双热插拔电源和高性能风扇。 • 如果需要连接到存储InfiniBand交换机、则必须支持Mellanox光纤InfiniBand缆线。 联想**SR665**： • 自定义NetApp型号包括支持双端口Mellanox ConnectX-6适配器所需的XiclityL控制器固件版本。有关订购详细信息、请联系NetApp。
8.	Mellanox ConnectX-6 HCA (适用于文件节点)。	• MCX653106A-HDAT主机通道适配器(HDR IB 200GB、双端口QSFP56、PCIe4.0 x16)。
8.	100万根HDR InfiniBand缆线(用于文件/块节点直接连接)。	• MCP1650-H001E30 (1米Mellanox无源铜缆、IB HDR、高达200 Gbps、QSFP56、30AWM)。 如果需要、可以调整此长度、以考虑文件节点与块节点之间的距离较长。

计数	硬件组件	要求
8.	HDR InfiniBand缆线(用于文件节点/存储交换机连接)	需要长度适当的InfiniBand HDR缆线(QSFP56收发器)、才能将文件节点连接到存储叶交换机。可能的选项包括： • MCP1650-H002E26 (2米Mellanox无源铜缆、IB HDR、高达200 GB/秒、QSFP56、30AWM)。 • MFS1S00-H003E (3米Mellanox有源光缆、IB HDR、高达200 GB/秒、QSFP56)。
2.	E系列块节点	两个EF600控制器配置如下： • 内存：256 GB (每个控制器128 GB)。 • 适配器：2端口200 GB/HDR (NVMe/IB)。 • Drives：已配置为与所需容量匹配。

软件要求

为了获得可预测的性能和可靠性、NetApp解决方案 上的BeeGFS版本会使用实施解决方案 所需的特定版本软件组件进行测试。

软件部署要求

下表列出了在基于Ansible的BeeGFS部署中自动部署的软件要求。

软件	**version**
BeeGFS	7.2.6
核心同步	3.1.5-1
起搏器	2.1.0-8.
opensm	openssm-5.9.0 (从mlnx_OFED 5.4.1.0.3.0开始) ⓘ 只有直接连接才需要启用虚拟化。

Ansible控制节点要求

NetApp解决方案 上的BeeGFS可从Ansible控制节点进行部署和管理。有关详细信息，请参见 "Ansible文档"。

下表中列出的软件要求特定于下面列出的NetApp BeeGFS Ansible集合版本。

软件	**version**
Ansible	2.11通过pip安装时：Ansible 4.7.0和Ansible核心< 2.12、>=2.11.6
Python	3.9.
其他Python软件包	加密-35.0.0、netaddr-0.8.0

软件	**version**
BeeGFS Ansible资料集	3.0.0

文件节点要求

软件	**version**
RedHat Enterprise Linux	具有高可用性的RedHat 8.4 Server物理服务器(双插槽)。 文件节点需要有效的RedHat Enterprise Linux Server订阅和Red Hat Enterprise Linux高可用性附加软件。
Linux内核	4.18.0-305.25.1.el8_4.x86_64
InfiniBand / RDMA驱动程序	收件箱
ConnectX-6 HCA固件	固件：20.31.1014
PXE：3.6.0403	UEFI：14.24.0013

EF600块节点要求

软件	**version**
SANtricity 操作系统	11.70.2
NVSRAM	N6000-872834-D06.DLP
驱动器固件	适用于所用驱动器型号的最新版本。

其他要求

下表中列出的设备用于验证、但可以根据需要使用适当的替代设备。通常、NetApp建议运行最新版本的软件、以避免意外问题。

硬件组件	已安装软件
• 2个Mellanox MQM8700 200 GB InfiniBand交换机	• 固件3.9.2110
• 1个可变控制节点(虚拟化)：* • 处理器：Intel ® Xeon ® Gold 6146 CPU @ 3.20GHz • 内存：8 GB • 本地存储：24 GB	• CentOS Linux 8.4.2105 • 内核4.18.0-305.3.1.el8.x86_64 已安装的Ansible和Python版本与上表中的版本匹配。

硬件组件	已安装软件
• 10个BeeGFS客户端(CPU节点)：* • 处理器：1个3.0 GHz AMD EPYC 7302 16核CPU • 内存：128 GB • 网络：2个Mellanox MCX653106A-HDAT (每个适配器连接一个端口)。	• Ubuntu 20.04 • 内核：5.4.0.100-generic • InfiniBand驱动程序：Mellanox OFED 5.3-1.0.3.0
• 1个BeeGFS客户端(GPU节点)：* • 处理器：2个2.5 GHz AMD EPYC 7742 64核CPU • 内存：1 TB • 网络：2个Mellanox MCX653106A-HDAT (每个适配器连接一个端口)。 此系统基于NVIDIA HGX A100平台、并包括四个A100 GPU。	• Ubuntu 20.04 • 内核：5.4.0.100-generic • InfiniBand驱动程序：Mellanox OFED 5.3-1.0.3.0

版权信息

版权所有 © 2024 NetApp, Inc.。保留所有权利。中国印刷。未经版权所有者事先书面许可，本文档中受版权保护的任何部分不得以任何形式或通过任何手段（图片、电子或机械方式，包括影印、录音、录像或存储在电子检索系统中）进行复制。

从受版权保护的 NetApp 资料派生的软件受以下许可和免责声明的约束：

本软件由 NetApp 按“原样”提供，不含任何明示或暗示担保，包括但不限于适销性以及针对特定用途的适用性的隐含担保，特此声明不承担任何责任。在任何情况下，对于因使用本软件而以任何方式造成的任何直接性、间接性、偶然性、特殊性、惩罚性或后果性损失（包括但不限于购买替代商品或服务；使用、数据或利润方面的损失；或者业务中断），无论原因如何以及基于何种责任理论，无论出于合同、严格责任或侵权行为（包括疏忽或其他行为），NetApp 均不承担责任，即使已被告知存在上述损失的可能性。

NetApp 保留在不另行通知的情况下随时对本文档所述的任何产品进行更改的权利。除非 NetApp 以书面形式明确同意，否则 NetApp 不承担因使用本文档所述产品而产生的任何责任或义务。使用或购买本产品不表示获得 NetApp 的任何专利权、商标权或任何其他知识产权许可。

本手册中描述的产品可能受一项或多项美国专利、外国专利或正在申请的专利的保护。

有限权利说明：政府使用、复制或公开本文档受 DFARS 252.227-7013（2014 年 2 月）和 FAR 52.227-19（2007 年 12 月）中“技术数据权利 — 非商用”条款第 (b)(3) 条规定的限制条件的约束。

本文档中所含数据与商业产品和/或商业服务（定义见 FAR 2.101）相关，属于 NetApp, Inc. 的专有信息。根据本协议提供的所有 NetApp 技术数据和计算机软件具有商业性质，并完全由私人出资开发。 美国政府对这些数据的使用权具有非排他性、全球性、受限且不可撤销的许可，该许可既不可转让，也不可再许可，但仅限在与交付数据所依据的美国政府合同有关且受合同支持的情况下使用。除本文档规定的情形外，未经 NetApp, Inc. 事先书面批准，不得使用、披露、复制、修改、操作或显示这些数据。美国政府对国防部的授权仅限于 DFARS 的第 252.227-7015(b)（2014 年 2 月）条款中明确的权利。

商标信息

NetApp、NetApp 标识和 http://www.netapp.com/TM 上所列的商标是 NetApp, Inc. 的商标。其他公司和产品名称可能是其各自所有者的商标。